



北京大学

本科生毕业论文

题目： 图灵测试与中文屋论证

**Turing Test and Chinese
Room Argument**

姓 名： 张石然

学 号： 1700012858

院 系： 哲学系

专 业： 哲学双学位

导师姓名： 李麒麟

二〇二一年六月

北京大学本科毕业论文导师评阅表

学生姓名	张石然	学号	1700012858
院系	哲学系	专业	哲学双学位
指导教师	李麒麟	职称	助理教授
毕业论文题目	图灵测试与中文屋论证 Turing Test and Chinese Room Argument		
导师是否同意参加 毕业论文答辩	同意	建议成绩 (可选填)	92
导师评语	张石然同学的本科毕业论文研究的是当代心灵哲学与人工智能哲学领域中关于“智能”与“理解”本质的理论问题，相关研究具有重要的哲学研究意义和理论价值。张石然同学结合了自己主学位的研究专长，在论文中集中讨论和评估了图灵（Alan Turing）与塞尔（John Searle）围绕机器思维与图灵测试所展开的相关争论，系统地展示和分析了相关理论主张的核心观点与主要论证，张石然同学还在此基础上尝试性地建构和提出自己对于相关论证根本症结的分析与评估。 在撰写该本科毕业论文，张石然同学在学术理论的深入学习、准确表述和批判性反思等诸多学术素养方面都得到了充分的训练；从初期确定论文主题、到中期研读和整理相关文献成果、再到最终构思和完成论文撰写的全部过程中，张石然同学的学术综合能力不断提高和进步，充分达到了哲学系哲学专业本科培养目标的各项训练要求和评估标准，值得肯定和称赞。 在相关问题的背景介绍、议题呈现、论证重构、辨证批判等方面，该论文都很好地达到了哲学本科毕业论文/哲学学士学位论文的学术标准。论文整体论述结构清晰，学术写作规范，语言表述流畅，论证思路合理，相关哲学探讨呈现出较强的系统性，因此，《图灵测试与中文屋论证》是一篇优秀的哲学本科毕业论文/哲学学士学位论文。 导师签名：李麒麟 2021 年 06 月 03 日		

版权声明

任何收存和保管本论文各种版本的单位和个人，未经本论文作者同意，不得将本论文转借他人，亦不得随意复制、抄录、拍照或以任何方式传播。否则，引起有碍作者著作权之问题，将可能承担法律责任。

摘要

在 1950 年发表的《计算机与智能》一文中，图灵构造了一个“模仿游戏”，用机器通过模仿游戏取代了对“机器是否能够思考”问题的肯定回答。图灵认为，通过图灵测试的机器就是智能的，图灵测试对回答机器智能的问题具有充分性。

塞尔在 1980 年对图灵测试和强人工智能的立场进行了反驳，通过“中文屋”思想实验，指出机器即使通过了图灵测试也并没有真正的智能。

本文力图论证塞尔对图灵测试的回应是有局限性的。全文共分为五个部分。第一部分是全文的引言。第二部分主要介绍人工智能的历史和背景。第三部分通过重构“模仿游戏”的设计和图灵假设的九点反驳，力图澄清图灵论证的主要思想。第四部分通过梳理“中文屋”的思想实验，阐释塞尔对图灵测试的批驳论证和步骤，同时这一部分还将讨论中文屋论证存在的缺陷及其有效性。第五部分是本文的结论：塞尔的中文屋论证并不能成功地否决图灵测试的充分性。

关键词：图灵测试，中文屋论证，人工智能

ABSTRACT

In the paper "Computing Machinery and Intelligence" published in 1950, Turing constructed an "imitation game" and suggested that the question "Can machines think?" could be answered positively if a machine can pass the imitation game. Turing believes that machines passing Turing test are intelligent, and Turing test is sufficient to answer the question of machine intelligence.

In 1980, Searle refuted Turing test and strong artificial intelligence thesis by the Chinese Room Thought Experiment, since he pointed out that a machine has no real intelligence even if it passes Turing test.

This thesis tries to demonstrate that Searle's response to Turing Test is limited. The whole thesis is divided into five parts. The first part is the introduction. The second part mainly introduces the history and background of artificial intelligence. The third part tries to clarify the main ideas of Turing's arguments by reconstructing the design of Imitation Game and nine refutations of Turing's hypothesis. In the fourth part, through combing Chinese Room Thought Experiment, this thesis explains Searle's critical argument and its steps against Turing's stand, and discusses the defects and validity of it. The fifth part is the conclusion of this thesis: Searle's Chinese Room Argument *cannot* successfully reject the adequacy of Turing Test.

KEY WORDS: Turing Test, Chinese Room Argument, Artificial Intelligence

目录

第一章 引言	1
第二章 人工智能简介	2
第三章 图灵测试及其可能的反驳	4
3.1 模仿游戏	4
3.1.1 模仿游戏的提出	4
3.1.2 模仿游戏与图灵测试	5
3.2 可能的反对意见	7
3.2.1 来自神学的反驳	7
3.2.2 “鸵鸟”式的反对意见	8
3.2.3 数学上的反对意见	8
3.2.4 基于意识的反驳	9
3.2.5 关于能力缺陷的反驳	10
3.2.6 洛夫莱斯夫人的反驳	11
3.2.7 基于神经系统连续性的反驳	12
3.2.8 基于行为非形式化的反对意见	12
3.2.9 基于超感官知觉的反驳	13
3.2.10 对九点反对意见的总结	13
第四章 中文屋论证及其有效性	14
4.1 “中文屋”思想实验	14
4.2 中文屋论证的重构	14
4.3 中文屋论证的缺陷及其有效性	15
第五章 结论	18
参考文献	19
致谢	20
北京大学学位论文原创性声明和使用授权说明	21

第一章 引言

1950 年，阿兰·图灵（Alan Turing）发表一篇名为《计算机与智能》（Computing Machinery and Intelligence）的文章。在文中，图灵提出了“机器能够思考吗？”（Can machines think?）的问题，并构造了一个“模仿游戏”（Imitation Game）试图给出解答。图灵认为，通过图灵测试的机器就是可以思考的、有智能的机器。

1980 年，美国哲学家约翰·塞尔（John Searle）发表了《心灵、大脑与程序》（Minds, Brains and Programs）一文，提出了著名的“中文屋”思想实验，针对图灵测试和强人工智能的立场进行了反驳，否定了图灵测试的充分性。他认为，人工智能无法拥有真正的智能，机器即使通过了图灵测试，也并不一定具有真正的智能。

图灵测试（Turing Test）和中文屋论证（Chinese Room Argument）在人工智能哲学领域内引发了两次讨论的热潮。

本文力图论证塞尔对图灵测试的回应是有局限性的。全文共分为五个部分。第一部分是全文的引言。第二部分主要介绍人工智能的历史和背景。第三部分通过重构“模仿游戏”的设计和图灵假设的九点反驳，力图澄清图灵论证的主要思想。第四部分通过梳理“中文屋”的思想实验，阐释塞尔对图灵测试的批驳论证和步骤，同时这一部分还通过对中文屋论证反驳的综述，讨论该论证存在的缺陷及其有效性。第五部分是本文的结论：塞尔的中文屋论证并不能成功地否决图灵测试的充分性。

第二章 人工智能简介

人们对于智能机器的构想远早于“人工智能”(Artificial Intelligence)这个概念的正式确立。

早在16世纪,笛卡尔就在《谈谈方法》中设想了一种智能机器:“如果有机器与我们的身体相似,并尽可能接近我们的行动……”虽然他从语言和理性两个方面否认了这种机器存在的可能性^①,但我们足以看见关于智能机器的讨论并非近世才开始。17世纪,莱布尼兹构想了一种“通用机”,可以通过“一种强大的符号语言来表达和计算所有的事情”

(Leibniz 1671)。1837年,查尔斯·巴贝奇(Charles Babbage)设计了一种分析机(Analytical Engine),使用打孔纸带进行十进制计数,被认为是世界上第一台计算机。1936年,图灵提出了通用图灵机(universal Turing machine)的模型,为算法和可计算性问题的研究提供了形式化的描述工具。1943年,沃伦·麦卡洛克(Warren McCulloch)和沃尔特·皮茨(Walter Pitts)发表了开创性的论文《神经活动内在意识的逻辑演算》(A Logical Calculus of the Ideas Immanent in Nervous Activity),为人工神经网络的研究奠定了基础。

1946年,第一台电子计算机ENIAC出现。1948年,世界上第一台电子存储程序计算机(electronic stored-program computer)SSEM(Small-Scale Experimental Machine)诞生,标志着计算机开始有能力存储程序指令。1950年,马文·明斯基(Marvin Minsky)建造了世界上第一台神经网络计算机(neural network computer)。同年,图灵提出了著名的图灵测试,尝试回答“机器是否能够思考”的问题,并对思考机器提供了设计性的构想。1956年,“人工智能”的概念在达特茅斯会议上被正式提出。^②

可以说,在“人工智能”概念被正式确立以前,人们就对智能形态的机器产生了足够多的构想。随着科技的不断发展,越来越多的类智能形态的计算机被设计、建造。在图灵测试和人工智能概念被提出后的七十年间,计算机也在不断地刷新人类的认知。1997年,IBM公司的深蓝(Deep Blue)在正常时限的比赛中首次击败了等级分排名世界第一的棋手,标志着国际象棋历史的新时代。2011年,IBM公司的Watson赢得了智力游戏节目《Jeopardy!》的冠军。2014年,软件“尤金·古斯特曼”(Eugene Goostman)首次通过了图灵测试。2016年,Google公司的AlphaGo战胜围棋世界冠军李世石。

那么,到底什么是人工智能呢?斯图尔特·罗素(Stuart Russell)等人在《人工智能:一种现代化方法》(Artificial Intelligence: A Modern Approach)一书中对这一问题给出了许多回答。这些答案根据人工智能的不同目标对人工智能给出了不同的定义,由两个维度——类人的(human)与理智的(rational)、思想(thought)与行为(action)——构成了四种类型,分别是像人一样行动(acting humanly)、像人一样思考(thinking humanly)、理智地思考(thinking rationally)、理智地行动(acting rationally,参见Russell & Norvig, pp. 4-11)。

^① 因为他在下文立刻指出:“我们仍应该有两种非常确定的方法来认识到它们不是真正的人。”参见Oppy & Dowe, p. 10。

^② 这一部分参考约翰·汉尼斯:《计算机体系结构:量化研究方法(第5版)》,机械工业出版社。

图灵测试的设计体现出其背后的立场，认为人工智能就是机器像人一样行动，它不关心机器具体是如何运行的，而只关注于机器与人交往的表现。有一些研究扩展了图灵测试，提出了完全图灵测试（total Turing test）的概念（Harnad 1991, p. 44），将人机交互场景从对话扩展到了现实世界当中。而第二种定义的立场则要求我们知道人类是怎么思考的，需要我们对人类心灵有足够精确的理论把握，因为只有这样才能判断机器是否在进行思考，是否真的足够智能。第三种定义则将人工智能导向了演绎推理（Syllogisms）、数理逻辑（Logicist）和概率论（Probability）。第四种定义则更关注于机器根据标准模式（standard model）做正确的事（do the right thing）。^①

我们看到，尽管人工智能的定义并不统一，但这四种立场导向了人工智能多维度的发展。图灵在《计算机与智能》一文最后写道：“我们可能希望机器最终能在所有纯智力领域与人类竞争。”^②虽然我们并不能确定是否真的存在纯智力一说，但至少就目前的技术水平来看，人工智能的发展远不足以支撑机器以出色的表现通过图灵测试。图灵测试和完全图灵测试对机器的要求可以拆解为目前主流的几大研究方向，包括自然语言处理（Natural Language Processing）、知识表征（Knowledge Representation）、自动推理（Automated Reasoning）、机器学习（Machine Learning）、计算机视觉（Computer Vision）和机器人学（Robotics）。

就人工智能在哲学方面的研究而言，丹尼尔·丹尼特（Daniel Dennett）认为，人工智能应被视为“对智力或知识可能性的最抽象的探究”（Dennett 1979, p. 64），应致力于解释智能，我们应该设计描述认知的抽象算法^③。这是一种自顶向下的策略。另一种进路是研究人本身，设计小型信息处理单元（small information-process units）从而自底向上地构建高级认知。

另一种对人工智能的分类是根据能力，将其区分为强人工智能和弱人工智能。弱人工智能指的是专注于且只能解决特定领域问题的人工智能，如前述的 Deep Blue、AlphaGo 等，而强人工智能又称通用人工智能，指那些可以胜任人类所有工作的人工智能。目前我们所认知的人工智能均是弱人工智能。

^① 四种定义的讨论具体参见 Russell & Norvig: “Artificial Intelligence: A Modern Approach,” pp. 4-11.

^② We may hope that machines will eventually compete with men in all purely intellectual fields. (Turing 1950, p. 460)

^③ AI should be viewed “as a most abstract inquiry into the possibility of intelligence or knowledge”. (Bringsjord & Naveen, pp. 61-66)

第三章 图灵测试及其可能的反驳

3.1 模仿游戏

基于上一部分讨论，我们知道图灵测试将人工智能定义为机器能够像人一样行动。在这一部分中，笔者将给出图灵测试的具体设计。在《计算机与智能》一文中，图灵通过设计模仿游戏，回避了对“机器是否能够思考”这个问题的直接回答，而是给出了对人工智能的操作性定义。实际上，我们会发现图灵并没有直接提出“图灵测试”这个概念，而只是提出了通过让机器参与模仿游戏来验证机器智能的办法。那么，模仿游戏本身是如何设计的？图灵测试与模仿游戏又有着怎样的关系？本节将就这两个问题展开讨论。

3.1.1 模仿游戏的提出

在《计算机与智能》一文中，图灵提出了“机器是否能够思考”的问题。他认为，回答这个问题的一种方式是什么是“机器”(machine)，什么是“思考”(think)，但这个方式在图灵看来并不能成功，而更像是一种统计调查(a statistical survey)，因为不同人对“机器”和“思考”的理解并不相同，我们很难界定“机器”和“思考”的概念。为了回答“机器能否思考”这个问题，图灵设计了一个模仿游戏的情形，将该问题替换成了“机器能否完成模仿游戏”。一般意义上，我们将机器参与的模仿游戏称作图灵测试^①。图灵认为，能够通过图灵测试的机器是能够思考的机器。换句话说，他认为图灵测试在回答“机器能够思考”这个问题上具有充分性^②。

让我们首先来看“模仿游戏”的情形(Turing 1950, p. 434)。游戏共有三个参与者，包括一个男人A、一个女人B和一个不限性别的提问者C。整个过程中，提问者C待在与男人A和女人B分开的房间里，他只知道他面对的两个人分别是X和Y。他可以通过提问来区分X和Y，如他可以向A和B询问：“请问X是否能够告诉我你的头发长度？”游戏中，提问者C的目标是确定他面对的X、Y两个人，哪个是男人A，哪个是女人B。游戏结束时，提问者C可以说“X是A，Y是B”，也可以说“X是B，Y是A”。男人A的目标是尽可能混淆提问者C的试听，让他给出错误的判断。而女人B的目标则是帮助提问者C辨别出她自己就是那个女人。

在模仿游戏的基础上，图灵进一步提出问题：“如果让机器去替换男人A的角色，会发生什么？”^③他给出了机器参与模仿游戏的情形，即提问者与“机器”对话，来判断这个“机器”到底是否是真正的机器还是人类。图灵给出了一些可能的问答场景，如提问者要求对方写一首诗、做一些数学计算、下棋等，而回答者也需要给出了一些与人类自然反应相

^① 这是一个比较粗略的界定。当我们深入分析模仿游戏和图灵测试，其实会发现模仿游戏和图灵测试的形式结构并不完全一致，比如模仿游戏的直接参与者有三个，而一般意义上的图灵测试只包含被测试的机器和提问者两方。辨析这两者的差异有助于我们更深刻地理解图灵测试的设计和内涵，具体的区别和阐释会在后文中详细给出。

^② 充分性意味着机器通过图灵测试这个条件能够推导出机器能够思考这个结果。笔者认为这是图灵展开全文讨论的重点，他假设的九点反驳均与其测试的充分性相关。

^③ What will happen when a machine takes the part of A in this game? (Turing 1950, p. 434)

近的回答，如“我不会写诗”，或者思考一阵再给出大数加法的答案。

这儿，图灵为了使得整个测试更加公平，在人的身体能力和智力能力上做了明确的区分，屏蔽了其他任何能够影响提问者判断的因素，如不让提问者看见、听到或触摸到与他对话的另一方，而只采取以文字为中介的交流方式。他给出了一种具体的办法——让双方待在互相隔离的屋子里，使用电传打字机进行交流——来达到这个目标。^①




图 3.1 图灵测试^②

在图灵的构想中，除了机器作为 A 和本来设定的提问者 C 参与之外，原先的角色 B 可以由人类替代。但图灵并没有进一步说明角色 B 的具体任务，而只是构想了机器的目标——尽可能混淆提问者 C 的视听，让提问者误以为机器就是人类。笔者理解，在图灵测试的一般场景下，人类作为角色 B 并不会出场，B 和 C 的角色都由提问者一个人充当。

图灵还给出了通过图灵测试的具体条件，他预计在五十年内，机器能够达到这样的水平：超过 30% 的人在五分钟的对话中都不能分辨出谈话对象是人还是机器。^③

可以看出，图灵测试是对机器智能的一种操作性定义。它并没有明确定义什么是“机器”、什么是“思考”，而是通过在具体场景中对机器行为的判断，来回答“机器能否思考”这个问题。

3.1.2 模仿游戏与图灵测试

模仿游戏的意义看起来并不直观，模仿游戏同图灵测试的近似性也并没有想象中的直接。在模仿游戏中，提问者 C 对 A 和 B 的区分是否只有性别特征？三个参与者的设计形式与提问者 C 直接判断 A 的性别的设计形式是否有差别？^④男人 A 在游戏中成功欺骗了提问者 C 意味着什么呢？这又能为我们理解图灵测试的意义带来什么启示？这一部分中，笔

^① 这个设置在图灵的文章中被多次提及，参见 Turing 1980, pp. 434-435.

^② 图片来自 <https://jaai.de/mensch-oder-maschine-der-turing-test-einfach-erklart-1385/>，访问日期：2021-06-01。

^③ 在原文中，图灵给出的是反面的表述：在未来的五十年内，机器能够做到在五分钟的谈话内，使人做出正确率不超过 70% 的判断。原文为 I believe that in about fifty years' time it will be possible to programme computers .. play the imitation game so well that an average interrogator will not have more than 70 per cent chance of making the right identification after five minutes of questioning. (Turing 1950, p. 442) 也有学者关心 30% 的界限是如何被确定的，本文不多做展开。

^④ 看起来这两种形式的游戏中，提问者 C 的辨别难度是不一样的。在模仿游戏中，C 可以根据 A 和 B 两方的回答进行判断，也可以借助一方的身份来推测另一方，但在没有 B 参与的场景中，C 确定 A 是男性还是女性的难度似乎变大了。

者重新分析了模仿游戏，将其与图灵测试的场景类比，说明了两者的异同。

让我们重新回到模仿游戏中。图灵设想了最直接的情景，即在问答过程中，女人 B 直接告诉提问者 C 自己就是那个女人，来使提问者 C 给出正确的判断。但这并不容易，因为提问者 C 完全有理由猜测男人 A 说谎了。我们假定男人 A 成功欺骗了提问者 C，赢了模仿游戏，那么这个游戏的意义是什么呢？

有反驳指出，即使 A 赢了这场游戏，使提问者 C 认为 A 比 B 更像是一个女人，也并不是以证实 A 就是一个女人。但在某种程度上，这个结果可以证明 A 对女性的一些特征有着深刻的洞见，以至于他能够将其叙述出来，在对话中“模仿”成一个女人来迷惑对话者。在生理性别上 A 不是女人，但也许在心理性别上我们可以认为 A 是女人。类比到图灵测试中，通过图灵测试的机器，实际上仍旧只是机器而不是人，但我们可以认为在一定程度上，这个机器理解人的某些特征，以至于它能够模仿这些特征，将这些特征在对话中展示出来。可以说，这样的机器虽然在生物层面上不属于人，但在智力层面与人相当，拥有人的思考能力，具有机器智能。^①

依据现有的机器的设计，图灵限制了对“机器能否思考”的问题的讨论。他关心的并不是当前机器拥有智能的可能性，也不关心是否所有机器都具备能够思考，他真正想问的是，是否有可能有机器能在模仿游戏中表现得很好。而这类机器被图灵限定在了离散状态机 (a discrete-state machine)^②上。图灵实际上将“机器能否思考”这个问题做了如下拆解：

- (a) 机器是否能够思考？
- (b) 机器是否能够在模仿游戏中替代 A 的角色完成游戏？
- (c) 是否可想象一台电子计算机在模仿游戏中表现良好？
- (d) 是否存在一台电子计算机 C，通过给这台机器扩容、提供合理的程序等一系列操作，使得它能在模仿游戏中成功扮演 A 的角色（其中 B 的角色由人扮演）？

笔者认为，对问题 (b) 的肯定回答能够推导出问题 (a) 的肯定回答，这两个问题本质上讨论了图灵测试的充分性。如果存在机器能够满足问题 (b)，那么问题 (a) 就能得到肯定的回答，这是图灵想说明的其测试的有效性。而问题 (c) 和 (d) 则讨论了通过图灵测试的机器的可能性。如果我们能设想一台机器满足 (d) 的条件，实际上我们能得到结论：一台被正确编程的机器可以通过图灵测试，这是图灵对机器能够思考的可能性的讨论。

因此，在图灵测试的设计中，实际蕴含着两个观点：

- (i) 图灵的模仿游戏为鉴定智能提供了很好的测试方案；
- (ii) 一台被正确编程的机器可以通过 (i) 描述中的测试。

其中，观点 (i) 被称作图灵测试的主张 (The Turing Test Claim)，观点 (ii) 被称作思考机器的主张 (The Thinking Machine Claim，参见 Oppy & Dowe, p. 28)。

^① 这个讨论实际上已经深入到了对图灵测试的一个反驳及其可能的回应，即机器对人类智能的成功模拟是否意味着机器本身具有智能。似乎在一般意义上，我们并不认为一个被模拟的事物与这个事物本身是一样的。如被模拟的火焰和真实的火焰显然有着很不相同的性质。参见 Douglas 1981, pp. 72-74.

^② 离散状态机是指状态可数的状态机，又称有限状态机。

延申这两点主张，我们可以得到更强的结果：

(i') 机器通过图灵测试就意味着它具有智能；

(ii') 存在这样一台被正确编程的机器能够通过 (i') 中的测试。

3.2 可能的反对意见

在《计算机与智能》一文中，图灵还考虑到了对图灵测试充分性的可能的反驳。这些意见包括（参见 Turing 1950, pp. 442-454）：来自神学的反驳（The Theological Objection），“鸵鸟”式的反对意见（The ‘Heads in the Sand’ Objection），数学上的反对意见（The Mathematical Objection），基于意识的反驳（The Argument from Consciousness），关于能力缺陷的反驳（Arguments from Various Disabilities），洛夫莱斯夫人的反驳（Lady Lovelace’s Objection），基于神经系统连续性的反驳（Argument from Continuity in the Nervous System），基于行为非形式化的反对意见（The Argument from Informality of Behaviour），基于超感官知觉的反驳（The Argument from Extra-Sensory Perception）。这一部分将陈述图灵假设的九个可能的反对意见，给出图灵对这个九点意见的反驳和笔者的补充。

3.2.1 来自神学的反驳

来自神学家的观点认为，上帝造物的时候，只把不朽的灵魂给予了人类，而并没有给予人之外的万物。思考作为属于不朽灵魂的特质，只属于人类，不属于动物，亦不属于机器，因此机器不能思考。来自神学的反驳可以被重构成如下的论证：

(1.1) 思考是属于不朽灵魂的特质。

(1.2) 只有人有不朽的灵魂。——神学观点

(1.3) 只有人可以思考。——由 (1.1) 和 (1.2) 得出

(1.4) 机器不是人。

所以，机器不能思考。——由 (1.3) 和 (1.4) 得出

图灵认为这种反驳不成立的原因一方面在于有神论本身并不被广泛接受，这个反对意见从前提就遭到了反驳，另一方面在于，即使我们接受了有神论，机器能够思考的这种可能性也不足以被这个反对意见驳倒。因为上帝的全能性意味着他完全有能力给机器赋予灵魂，使它能够思考。

这种神学的反驳也可以解释为一种实体二元论 (substance dualism) 的立场（参见 Oppy & Dowe, pp. 11-12），认为思维 (mind) 是一种独立于身体 (body) 的非物质性存在，本质上是思考的东西 (a thinking thing)，与身体共同构成了“人”。在实体二元论的视角下，思维（神学观点即人的灵魂）与身体的结合变成了上帝的工作，是上帝使人能够思考，也只使人能够思考。因此，机器与其他的物质实体没什么不同，并不能进行思考。

反思这种立场，除了有上述两点反驳之外，我们发现实体二元论本身受到的抨击也很多，即将“灵魂”看作是某种独立的非物质性存在这个做法本身就有很大的缺陷。

3.2.2 “鸵鸟”式的反对意见

图灵给出的这个反对意见认为机器思考带来的后果是可怕的，因此不接受机器能够思考这个可能。基于这个立场的观点认为，“机器能够思考”可能会带来三个递进的问题（参见 Oppy & Dowe, pp. 12-13）：

- (a) 机器能够思考会动摇人类优于宇宙中其他事物的信念基础；
- (b) 能思考的机器的出现可能会取代人类，因为能思考的机器很有可能比人类思考得更好；
- (c) 人类可能会被能思考的机器支配，人类可能会被奴役或被消灭。

这类反驳本质上是一种情感上的不愿接受，其出发点主要是人们过于看重思考的力量（the power of thinking）和价值。图灵认为这一类反对意见并不值得反驳，而更应该被给予安慰。

3.2.3 数学上的反对意见

哥德尔不完备性定理（Gödel's incompleteness theorems）告诉我们，一个包含皮亚诺算术公理的形式系统不能同时满足相容性与完备性，其中相容性是指体系的逻辑自治，完备性指的是体系中的任意命题都可被证明或证伪。其第一条定理就直接指出了：任何相容的形式系统，只要蕴涵皮亚诺算术公理，就可以在体系中构造既不能证明也不能证伪的命题。而图灵的停机问题（the halting problem）则进一步揭示了程序的有限性：不存在这样一个程序算法，它能够计算任何程序在给定输入上是否会停机。^⑩数学上的反对意见正是基于哥德尔不完备性定理，指出有些事情是机器做不到的，而这在图灵测试的场景下就意味着对于有些问题，机器只能给出错误的答案，甚至无法给出答案。但对于人来说，这些问题都是可以被解答的。

将这个反驳论证重构如下（参见 Oppy & Dowe, pp. 13-15）：

- (3.1) 假定 C 是一台计算机。
- (3.2) 因为 C 遵循哥德尔不完备性定理，所以存在问题 Q，使得 C 无法回答。——由 (3.1) 得出
- (3.3) 如果实体 E 不遵循哥德尔不完备性定理，那么不存在 E 无法回答的问题。
- (3.4) 人不遵循哥德尔不完备性定理。
- (3.5) 所以，不存在人无法回答的问题。——由 (3.3) 和 (3.4) 得出
- (3.6) 因此，人能够回答问题 Q。——由 (3.5) 得出
- (3.7) 在图灵测试中，通过询问 Q，可以判断回答者究竟是机器还是人。

从而，对于 C 来说它可能无法通过图灵测试。——由 (3.2) 和 (3.7) 得出

在这个论证中，图灵主要攻击了前提 (3.4)，他认为数学上的反对意见并不能证明（without any sort of proof）人不遵循哥德尔不完备性定理。因为人本身也会给出很多错误

^⑩ 与哥德尔不完备性定理相关的还有丘奇（Church）定理，罗塞尔（Rosser）的不完备定理等等。

的答案，但很多时候人会因为回答对了机器答错的问题而产生优越感，从而认定机器不能够思考。但是，图灵认为也可能出现相反情况，即机器回答对了人答错的问题，因此看起来总是有比机器更聪明的人，也会有比人更聪明的机器，从而这个反驳并不成立。在这儿图灵想说的是，既然我们不能确证人不遵循哥德尔不完备性定理，也就没有理由轻易地否定机器能够思考的可能。

延续图灵的讨论，我们完全可以设想一个可以思考的智能机器人，在遵循哥德尔不完备性定理的情况下没有通过图灵测试（如考官问了很多它不会的问题），但我们依旧不会认为它不能思考，也没有可靠的理由认定它不能够思考。而除了图灵指出的人可能同样遵循哥德尔不完备性定理之外，笔者认为，即使人真的不遵循哥德尔不完备性定理，思考能力本身和哥德尔不完备性定理的关系到底有多密切，也值得商榷。此外，前提（3.3）的正确性有待考证。这是哥德尔不完备性定理的否命题表述，但一个命题成立并不保证该命题的否命题成立。

根本上来说，数学上的反对意见并没有抓住图灵测试的设计思想的核心。不能够通过图灵测试并不意味着机器不能够思考，这个论证并没有反驳图灵测试的充分性，而只能说明图灵测试并不是机器思考的必要条件。

3.2.4 基于意识的反驳

这个反对意见主要可以被组织成如下三个论点（参见 Oppy & Dowe, pp. 16-17）：

- (i) 唯一能够确定机器在思考的方法是成为机器，并感觉到自己在思考。^①
- (ii) 有意识不仅意味着行动，而且需要意识到自己的行动。^②
- (iii) 存在着独立于情感和欲望的智力影响着人类行为。^③

图灵引用了教授杰斐逊（Professor Jefferson）1949 年的 Lister 演说（Lister Oration）来建立这个反驳的论证。图灵认为，这类反驳的一种可能形态是唯我论（solipsism），认为除了“我”以外没有任何东西存在，外部世界都是“我”的经验、感觉或意识，即上述的论点（i）。针对“唯我论”，图灵指出这种观点并不有利于我们展开日常生活，因为我们在日常生活中通常不会站在唯我论的立场与人交往，因此我们也不能为这类立场给予充分的理由。实际上，坚持唯我论也并不能对机器智能做出有效的反驳，它本身是怀疑论的一种形态，并不能充分地反驳图灵测试的充分性。

此外，针对上述的论点（ii）和（iii），图灵认为，某种程度上，机器的“言说”或表

^① 这个观点就是唯我论的一种具体表述，对应的原文是图灵对这类反驳的引申：“According to the most extreme form of this view the only way by which one could be sure that a machine thinks is to be the machine and to feel oneself thinking.”（Turing 1950, p. 446）意思是这种反驳的最极端形式是能确定机器思考的唯一方式是成为机器，并知道自己思考。

^② 这里对应的原文是图灵引用的杰斐逊教授的演说：“Not until a machine can write a sonnet or compose a concerto because of thoughts and emotions felt, and not by the chance fall of symbols, could we agree that machine equals brain—that is, not only write it but know that it had written it.”（Turing 1950, pp. 445-446）这儿的关键在于想表达拥有大脑的人类的智力不仅在于人本身去行动，更在于意识到自己的行动。

^③ 这里对应的原文是：“No mechanism could feel (and not merely artificially signal, an easy contrivance) pleasure at its successes, grief when its values fuse, be warmed by flattery, be made miserable by its mistakes, be charmed by sex, be angry or depressed when it cannot get what it wants.”（Turing 1950, p. 446）这段话的潜在立场是认为机器的智力行为和感情欲望并不是一体的，而是可以分离的。

现出的行为就足以证明机器的思考能力。他设想了“口试”(viva voce)的场景^①，我们认为如果考生顺利回答了考官的问题，这个考生就是有感情和理解能力的，而不仅仅只是一个简单的装置，也不只是一个能回答问题的智力机器。笔者认为，一方面图灵在这个反对意见下避免了唯我论的走向及其对图灵测试充分性的不实指控，另一方面也强调了人类智力、情感和行为的一体性，我们有充分理由认为一个物体在看起来很智能的时候它就是具有智能的——而这也正是图灵测试所想要解决的关键。

3.2.5 关于能力缺陷的反驳

这个反对意见认为机器并不具有人类的一些特征，包括：仁慈、机智、漂亮、友好、幽默、有正义感、爱吃草莓冰激凌等^②，这些特征体现了人类行为的多样性，而人类行为的多样性是人类智能的证明。因为机器看起来不可能具有这些特征，不可能具备足够的行为多样性，因此机器不能够思考。

重构这个观点我们可以得到如下论证：

(5.1) 人类行为的多样性能体现人类的智能。

(5.2) 如果一个物体具有智能，那么这个物体的行为能表现出多样性。——由(5.1)引申

(5.3) 如果一个物体不能表现出人类一样的行为多样性，那么这个物体不能够思考。——由(5.2)推出

(5.4) 机器无法具有像人类一样的行为多样性。

所以，机器不能够思考。——由(5.3)和(5.4)得出

图灵将这类意见的基础(在重构中对应前提(5.4))归于科学归纳法的原则(the principle of scientific induction)，因为人们接触到的机器不具备充分的行为多样性，因此持有这类观点的人们推测未来的机器也不会发展出足够的行为多样性。

针对行为可能的多样性特征，图灵做了两方面的分类并分别给予了回应。一方面，针对机器不能像人类一样爱吃草莓冰激凌之类的观点，图灵认为机器具有这种特征似乎是一件不必要的事情，因为这并不足以使得我们认为机器能够思考。另一方面，有观点认为机器不会犯错，它致命的精确性足够将它和人区分开来。图灵将机器可能犯的错误分成了两类，一类是功能上的错误(errors of function)，另一类是结论上的错误(errors of conclusion)。功能上的错误是指机器的机械故障，但当我们讨论通用图灵机等抽象模型的时候，这类功能上的错误并不可能，在这个意义上我们可以认为机器永远不会犯错。而针对结论上的这一类错误，图灵认为我们并没有充分地理由来证明机器不能犯错，甚至我们可以将机器设

^① 为了帮助理解，我们完全可以设想在雅思考场里考生和考官对话的场景。即使考官通过机器与考生对话，只要回答合理，考生也不会被认为是一个只会回答问题的、没有感情的机器；相反，如果考生对问题回答得不好，也很难会被看作是一个由一堆代码组成的程序。

^② 图灵在这儿共列举了十六个特征，包括：(1) be kind; (2) be resourceful; (3) be beautiful; (4) be friendly; (5) have initiative; (6) have a sense of humor; (7) tell right from wrong; (8) make mistakes; (9) fall in love; (10) enjoy strawberries and cream; (11) make someone fall in love with one; (12) learn from experience; (13) use words properly; (14) be the subject of one's own thoughts; (15) have as much diversity of behavior as a man; (16) do something really new (Turing 1950, p. 447)。

计“会犯错”的机器。在这个意义上，图灵认为机器是可以具有这类特征的。

图灵将这种行为多样性的缺乏归结为机器有限的存储空间，当未来机器的存储容量足够大的时候，我们可以设想机器通过观察它自身的行为来调整自己的程序，以更有效地实现某种目的，如展现出行为的多样性。

本质上，机器拥有行为的多样性对我们理解和认定机器具有智能到底有多大帮助，是一件值得怀疑的事情。“喜欢吃草莓冰激凌”的这个例子触及到了这个问题——具备这些特征对于机器智能来说似乎并非一件必要的事情。这个反对意见认为行为多样性是智力的一种体现，但我们似乎并没有办法确认这种多样性就是智力的本质。这一点可以关联到前文重构中前提（5.2）到中间结论（5.3）这一步论证。

当我们考察这个反对意见的论证重构时，我们会发现前提（5.2）到中间结论（5.3）的这一步并不是有效的。前提（5.2）本质上是个语义的推理而不是语形推演^①，而语义推理并不满足逆否化操作的要求，因此即使前提（5.2）成立，（5.3）也不能得到充分的辩护。所以，这个反对意见本身的论证就存在着不合理性。此外，结论（5.3）的立场本身也可以受到质疑。在这一点上，图灵给出了对未来机器的设想，我们不能否认这种可能性，即在机器发展到一定程度之后，它自身体系的复杂性就给它带来了行为的多样性，只是这种多样性区别于人类行为多样性而已。

因此，我们认为这个论点也不足以构成对图灵测试充分性的反驳。

3.2.6 洛夫莱斯夫人的反驳

这个反驳认为分析机（Analytical Engine）只能做那些我们知道怎样命令它去做的事情^②，它所能完成的事情都在人类的掌控之内，并不能创造出新的东西，也不能给我们惊喜。

对此，图灵认为，一方面，机器并不是不能让我们吃惊，这个观点只看到了分析机的一种特性，而没有看到分析机进行思考的可能性。他指出，机器如果拥有足够的存储空间和运行速度，那么就有可能通过适当的编程达到能够与人对话的状态。对此，图灵设想了一种学习机器（learning machine）。他认为，一个成年人的心灵（an adult human mind）具有如下三个成分：

- （i）出生时的原始心灵状态
- （ii）所受到的教育
- （iii）其他不属于教育的经历

图灵的目标不是要造出这样一个心灵，而是设计一个模拟儿童心灵的程序（the child-programme）和对这个程序的教育过程（the education process），使得它可以通过学习（learn）

^① 语义推理是指由命题 p 可演绎推出命题 q ，即从 p 到 q 的推理是有效的，记为“ $p \Rightarrow q$ ”。由 p 向 q 的推理有效并不保证由 q 向 p 的推理有效。语形推演是指命题 p 实质蕴涵命题 q ，即命题“ $p \rightarrow q$ ”为真，记为“ $p \rightarrow q$ ”。如果命题“ $p \rightarrow q$ ”为真，那么命题“非 $q \rightarrow$ 非 p ”亦为真。但这在语义推理中并不适用，因为语义推理是讨论形式系统的元语言，不属于形式系统。我们甚至不会称“ $p \Rightarrow q$ ”为一个命题，更不会赋予真值。而语义推理并不能像语形推演一样满足逆否化操作的要求。

^② 这里对应的原文为：“The Analytical Engine has no pretensions to originate anything. It can do whatever we know how to order it to perform.”（Turing 1950, p. 450）。

来成长为一个成年人的心灵。

另一方面，人类是否真的能创造出新的东西也有待考究。当洛夫莱斯夫人的观点将机器还原为程序的运行的时候，这个立场是否也可以将我们的思维过程还原为神经元之间的电信号传递？图灵给出了一个“洋葱皮”（skin of an onion）的比喻，他指出：当我们将心灵像剥去洋葱皮一样一层层揭开的时候，我们是否能够得到“真实的”心灵？还是将什么也得不到？图灵并没有给出解答，而是将问题留待给时间检验。

3.2.7 基于神经系统连续性的反驳

在这个反对意见中，反对者认为大脑的结构和计算机的设计并不相同，神经系统所具有的连续性^①和计算机的离散性使得机器永远不可能成功地模仿一个人思考。

图灵承认从本质上来看，离散状态机与连续状态机（a continuous machine）^②并不相同。但图灵指出，我们可以设想某种最简单形态的连续状态机——他举了微分分析器（a differential analyser）^③的例子——在行为上观察者无法将其与离散状态机的行为进行区分。因此，图灵认为，这种差异对图灵测试充分性的影响是无关紧要的，机器可以刻画为连续状态机并不是机器可以思考的一个充分条件。

重新回顾这个反驳，笔者认为该反驳预设了神经系统具有连续性，并且人的思维只能来自于这种连续的神经系统。如果我们能够确证，人类大脑确实是这样一个类似连续状态机的系统，且人类思维能且只能来自于这样的系统，那么图灵的立场似乎可以在一定程度上受到质疑，因为这个前提要求了能够思考的机器必须符合连续状态机的设计，这样图灵对离散状态机能够通过图灵测试的构想也就不成立了，亦或有离散状态机通过了图灵测试，那么图灵测试的充分性也就会受到反驳。但也有一些哲学家认为，这种前提不成立（Dennett 1991, pp. 431-455）。一方面，我们基于何种理由确证思维只能来自于这种连续的系统？另一方面，我们也没有充分的理由否认人类的大脑本质上就是一台离散状态机。如布洛克指出，在我们“智力”（intelligence）的概念中，没有什么能排除由量化的感官装置（quantised sensory devices）和电子工作部件（digital working parts）构成的智力因素，即我们也无法确定我们的智力是否一定来自于与机器不同的设计（Block 1981）。

3.2.8 基于行为非形式化的反对意见

这个观点认为，人类应当遵循一套行动准则来行动，但人通常不会严格遵循这些准则，而机器是根据一套规则来运行的，因此在行为的不确定性方面，机器产生了和人的不同，我们不能认为机器是人。这个反驳可以被重构成如下的论证：

- （8.1）机器由一套规则决定它的行为。
- （8.2）如果人可以是机器，那么人的行为也应该被一套有限的规则决定。
- （8.3）没有这样的一套规则决定人的行为。

① 但“连续性”并没有得到足够的科学理论支持。

② 连续状态机指拥有无限的、非离散状态的状态机。

③ 微分分析器是主要用数字方法解算微分方程的专用计算机，接受任意自然数的输入，属于连续状态机的一种。

所以，人不是机器。

针对这个论证，图灵提出了两个概念：“行动准则”（rules of conduct）和“行为规律”（laws of behaviour）。前者意味着人“应该”（ought）做什么，而后者表示人“将要”（will）做什么。他认为，主导机器的规则是类似人类行为规律之类的自然规律，而非人为制定的行动准则。如果这样对应关系存在，一方面，在行为规律的解释下，论证的前提（8.3）应该指出人类是受自然规律支配的，而不应该预设不存在这样一套规则。另一方面，如果这样的规则被解释成行动准则，那么前提（8.1）的假设——机器存在一套行动准则去支配它的行为——是否依旧成立？一般来说，我们更倾向于用行为规律层面的理解去解释机器的运转，而不会用机器“应该”做什么来要求它。因此，通过这个论证得到人不是机器的结论也是不正确的。

但是，这个反对意见给我们启示，如果人类行为不是由决定论支配的，即不存在影响人类行动的行为规律，那么机器是否有可能同样不由决定论支配。因为从当前的技术水平来看，机器就是由人类根据一些固定规则设计而来的。不过本质上来说，这个反驳依旧只集中讨论了机器是否能够像人一样思考的可能性，而没有针对图灵测试及其充分性给出有效反驳。

3.2.9 基于超感官知觉的反驳

图灵预想的最后一类反驳是假设了模仿游戏中的参与者具有“超感官知觉”（Extra-Sensory Perception）的情形。在这类反驳设定的场景下，提问者和作为人类的参与者可以通过如心灵感应（telepathy）等方式进行交流，而机器却无法拥有这种功能，从而导致图灵测试失效。

这个反驳预设的情形在现在看来并不真实。即使我们承认心灵感应的存在，我们也可以设想机器具有同等的超感知能力，从而避免在游戏的不公平。图灵对这个反驳给出的解决方案是设计一种“超感知屏蔽室”（a telepathy-proof room），我想这也是他针对其他图灵测试可能失效的情形给出的一种通用的辩护——我们总可以找到一种方式，使图灵测试按照预先的设计进行，从而维护了图灵测试的有效性和充分性。

3.2.10 对九点反对意见的总结

图灵在这个九个观点后写道，他“没有非常有力的正面论据来支持自己的观点，否则也就不必这么费力地指出反对意见的谬误了”（Turing 1950, p. 454）。笔者认为，在上述九种意见中，图灵假设的大部分反驳都直接攻击了“机器不能思考”或“机器不能通过图灵测试”这个结论，从外部否定了图灵的立场，试图说明图灵测试的局限性，而没有对图灵测试的充分性给予内在的反驳。相反，倘若一个反驳能够论证通过图灵测试的机器也不能思考，那么这样的反驳似乎才给予了图灵测试最本质的诘难。在下一章中，笔者将对图灵测试的诸多诘难中最为出名的一个——中文屋论证——进行分析和重构，阐释这个诘难在多大程度上有效地反驳了图灵测试的充分性。

第四章 中文屋论证及其有效性

4.1 “中文屋”思想实验

中文屋论证是对图灵测试的诸多反驳中备受瞩目的一个。

在《心灵、大脑和程序》中，约翰·塞尔构建了著名的“中文屋论证”，试图反驳了强人工智能的两个观点：恰当编程的计算机实际上具有认知状态；这样的程序因此解释了人类的认知^①。塞尔在文章中指出，虽然他的反驳主要针对罗杰·尚克（Roger Schank）等人在1977年提出的构想，但这一类反驳对任何模拟人类心灵的图灵机都通用，即塞尔认为，他的反驳能够证明强人工智能的观点是错误的。

我们首先来看“中文屋”思想实验的基本情形：设想一个封闭的屋子，里面有一个只会英文的人，屋外的人试图用中文与这个屋子进行交流。通过输入中文故事和问题，屋里的人根据一些预先定义的英文规则找到问题对应的中文回答，并传递给屋外的人。对于屋外的人来说，这个屋子是会中文的，然而似乎我们并不会认为这间屋子和屋子里的人会中文，也不认为他们能对输入的故事和问题产生任何实际的理解（understanding，参见 Searle 1980, pp. 417-419）。

塞尔又将这个思想实验推进了一步。他提出，屋子里的人对于英文版的故事能给出理解，但设想屋里的人是个中英互译的熟练工，他将输入的中文翻译成英文，给出对应的回答再翻译成中文，对屋外的人来说，屋子里的人好像是懂中文的，但其实他只是进行了未加以理解的翻译工作。

结合塞尔的论证目标，这个思想实验带来如下论证：

(1.1) “中文屋”思想实验构成了强人工智能的一个反例

所以，强人工智能是错误的。

但“中文屋”思想实验何以构成了强人工智能观点的一个反例？在塞尔看来，中文屋构想了一个可以通过图灵测试标准的强人工智能程序，但这个程序本身对话的时候并不能对中文产生任何实质的理解，不具有认知状态。与此同时，这样的程序也不能解释人类的理解（explain human understanding），因为计算机程序从本质上是按照功能运作的（functioning），并不存在理解的过程。

在下两节中，笔者将给出图灵测试场景下中文屋论证的重构，并试图通过澄清并反驳“中文屋不存在理解的过程”这一命题，证明塞尔设计的“中文屋”思想实验对图灵测试的回应是有限的。

4.2 中文屋论证的重构

在第三章中，我们可以发现，图灵测试的立场蕴含着如下两个论点：

(i) 机器通过图灵测试就意味着它具有智能；

^① 这儿对应的原文是“the claim that appropriately programmed computers literally have cognitive states and that the programs thereby explain human cognition”（Searle 1980, p. 417）。

(ii) 一台被正确编程的机器能够通过图灵测试。

通常意义上，我们认为中文屋论证对图灵测试给予了一定反驳，但塞尔究竟反驳了图灵测试的哪一个论点？更况塞尔最直接反驳的对象并非图灵测试，而是强人工智能的存在性，那么人们何以认为中文屋论证对图灵测试构成了一个反驳？笔者认为，虽然塞尔所要反驳的强人工智能的两点立场与图灵测试所蕴含的观点之间有一定差异，但这个思想实验的设计继承了图灵测试的框架。塞尔以作为机器智能判断标准的图灵测试为前提，设计了“中文屋”思想实验，并借以反驳了由图灵测试展开的强人工智能的存在性问题。他最终想要达到的目标是否定强人工智能的存在性，并论证得到“一台被正确编程的机器即使通过图灵测试也无法拥有智能”的结果。因此，而这个否定性的结论动摇了作为前提的图灵测试的充分性。

中文屋论证指出，如果中文屋满足条件：

- (a) 能够被正确编程；
- (b) 能够通过图灵测试；
- (c) 不具有智能。

那么，这个“中文屋”构成了图灵测试充分性的一个反例，从而也就可以说明图灵测试不具有回答机器智能的充分性。但这三个条件构成的场景，如何说明中文屋中没有理解产生？进一步细化这个推理，我们发现这是一个归谬法，笔者尝试给出如下论证重构：

- (2.1) 假设图灵测试的充分性成立，即机器如果能够通过测试，那么它能思考。
- (2.2) 在“中文屋”思想实验的场景中，我们认为中文屋 CR 能够通过图灵测试。
- (2.3) CR 具有智能，能够思考。——由 (2.1) 和 (2.2) 得出
- (2.4) 但实际上这个场景中并没有任何“理解”产生。

所以，图灵测试的充分性不成立。——由 (2.3) 和 (2.4) 归谬得出

那么，“中文屋”的场景何以说明了前提 (2.4)，即为什么中文屋在与屋外的人交流的过程中没有任何“理解”产生？下一节，笔者将围绕针对这个前提的批评展开讨论。

4.3 中文屋论证的缺陷及其有效性

笔者认为中文屋论证的核心是上一节的论证重构，而大多数批评都是针对其中的前提 (2.4) 展开的。前提 (2.4) 指出，在中文屋场景下没有任何“理解”产生。针对这个结论我们自然能给出问题：这个过程中是否真的没有理解产生？

针对这个问题，中文屋论证可以给出两个场景的重构：

论证 (A)

(1) 中文屋中的人只是在进行一些机械化的符号操作，本身并没有理解中文
所以，中文屋中没有任何理解产生。

论证 (B) (参见 Cole 2008, pp. 44)

- (1) 程序是纯形式的 (formal)、语法的。
- (2) 人类思维是有语义内容的。

(3) 语法本身不构成也不足以构成语义。

所以，程序本身不构成也不足以构成人类的思维。

论证(A)依旧集中在了中文屋的场景下进行讨论，其关键在于通过否定屋里的人能产生对中文的理解，进而否定中文屋能产生实质的理解。而论证(B)则直接将中文屋替换成了程序^①，通过抽象对比程序运行的性质和人类理解的性质之间的区别，来论证程序无法拥有人的思维特性。

对于论证(A)，一些反驳虽然承认了中文屋中的人不能理解中文这个前提，但并不承认推导过程的成立。一方面，有学者认为整个中文屋可以类比成一台计算机，屋里的人就是机器的CPU，虽然他不能理解汉字，但是他身处的整个系统可以。^②另一方面，也有学者指出，整个运作的系统可以产生一个新的虚拟实体，这个实体类似于Apple Siri，能够通过符号操作产生对汉字的理解。^③对这个论证的一个更为激进的反对观点直接否定了该论证的前提，认为屋里的人在对汉字的操作过程中可能会产生对中文的理解。

也有一些批评的观点指出，虽然人类和机器在这样的场景下都不能产生理解，但我们可以设想一种类人的机器按照中文屋的设置运行，并产生实质的理解。他们给出了两类反驳。一类反驳认为我们可以构想一种能够像人一样活动的机器人，它拥有机械臂、视觉感受器等装置，可以通过在房间里的活动将符号和意义相对应，并对自然语言产生真正的理解。^④另一类反驳则从生物学层面构想了一个类人的机器，它能够通过程序模仿汉语母语者理解汉语时的神经放电序列，因生物学结构上的雷同而产生和人类一样的理解。^⑤

在论证(A)的这两个回应之外，还有一类回应并没有直接攻击中文屋论证，而是反对了论证之外的预设。有一类观点试图直接否定中文屋论证中对机器不能思考的直觉性预设，指出直觉并不一定可靠，我们需要对直觉保持警惕。^⑥还有一类观点通过对比人类日常交往的行为，指出如果我们不能根据中文屋的行为确定中文屋能产生理解的话，那么我们根据他人的行动推断他人具有思维也是不合理的。换句话说，这个观点尝试根据机器的行为表现赋予机器一种“理解”的可能性。在日常生活中，我们总习惯性地预设交往的对方是一个能思考的智能生物，而后基于这样的预设尝试理解他人的理解。既然如此，我们凭什么有理由认为一个能与人聊天的机器就没有思维能力？可以看出，这个观点是诸多对中文屋论证的反驳中最接近图灵测试立场的一个，即我们可以基于聊天者的行为表现判断对方的智能。^⑦

论证(B)意在说明，机器基于自身的特性而不能产生理解。塞尔认为，机器使用的是形式化的语法规则来操作字符串，实际上对语义没有任何理解。而人的大脑是具有智能的，人的心灵具有意向性(intentionality)，能对语义产生理解。这两者本质上是不同的，因此

^① 在塞尔本来的构想中，中文屋的情形也是可以恰当编程的。

^② 这一类回应被称为系统回应(the System Reply，参见 Searl 1980，pp. 419-420)。

^③ 这一类回应被称为虚拟心灵回应(the Virtual Mind Reply，参见 Cole 2008，pp. 20-24)。

^④ 这一类回应被称为机器人回应(the Robot Reply，参见 Searl 1980，pp. 420-421)。

^⑤ 这一类回应被称为大脑模拟器回应(the Brain Simulator Reply，参见 Searl 1980，p. 420)。

^⑥ 这一类回应被称为直觉回应(the Intuition Reply，参见 Cole 2008，pp. 38-43)。

^⑦ 这一类回应被称为其他心智回应(the Other Minds Reply，参见 Searl 1980，pp. 421-422)。

机器永远不可能像人的大脑一样具有智能。塞尔对“理解”的解释坚持了还原主义的立场，将人类的理解能力还原为了心灵对语义的拥有，而将程序还原为了纯形式的语法表达。这一论点的最终结论是，思维必须来自生物过程，机器最多只能对这些生物过程进行模拟。

针对这个立场，有一些哲学家认为，论证（B）的前提（1）中所描述的程序的纯形式状态并不正确，因为实际的机器是一个极其复杂的电子因果系统（an enormously complex electronic causal system），与抽象的、语法的形式系统完全不同。此外，他们认为机器对语法的处理也与人类完全不相同，晶体管的二进制运作方式使得机器可以处理语法问题，但这种运作方式对于机器来说并不意味着语法本身，因此不能够将机器与纯形式的语法相等同。（Cole 2008, pp. 15-45）也有一些哲学家针对这个论证本身的推理给出了质疑。他们认为，即使程序的形式化和人类心灵的意向性有差异，但这种差异并不是对立的。换句话说，语法与语义并非两个不相关的概念，而是互相补充的。因此论证（B）得到的结论过于绝对，中文屋论证对图灵测试充分性的反驳不够有说服力。

综上，笔者认为中文屋论证在第二节的论证重构的结构上对图灵测试充分性的反驳是有效的，但其中“中文屋场景中不能产生理解”的前提本身却蕴含着许多弱点。基于上述讨论，笔者认为，我们依旧可以将图灵测试作为测试机器能否思考的一个指导性标准。中文屋论证的直觉性预设回避了机器思考的可能性，而图灵测试作为一个操作性定义，积极地赋予了机器思考的可能性，坚持这种立场使得我们能够更为审慎地反思这种可能，并在必要的时候接受这种可能。总体来说，图灵测试的开放性使得辩护者拥有更坚定的立场去维护它，去相信机器思考的可能。

第五章 结论

基于上面的讨论，笔者认为，塞尔的中文屋论证对图灵测试充分性的反驳是有局限的。尤其在中文屋论证的关键前提——中文屋场景中不能产生理解——上，塞尔的论证蕴含着诸多弱点。

图灵测试提示了图灵的行为主义立场，认为人工智能就是机器能够像人一样行动，而塞尔的中文屋论证使塞尔看起来更像是一个还原主义，坚持认为人工智能应当能够像人一样思考。因此中文屋论证在反驳图灵测试的充分性时，就不可避免地需要解释“思考”本身的含义，将图灵测试的操作性定义重新转移到了对于思维、意识等关于人自身的哲学概念的讨论上。相比之下，图灵测试的行为主义立场更符合日常生活的直觉，同时也积极地赋予了机器思考的可能性。

基于上述讨论，笔者倾向于认为，塞尔的中文屋论证及其还原主义的立场，在彻底反驳图灵测试的充分性及强人工智能的可能性上，似乎是有很大局限的，我们依旧可以将图灵测试作为机器智能的一个指导性标准。

参考文献

- [1] Turing, A., 1950, "Computing Machinery and Intelligence," *Mind: A Quarterly Review of Psychology and Philosophy*, 433-460.
- [2] Searle, J., 1980, "Minds, Brains and Programs," *Behavioral and Brain Sciences*, 3: 417-424.
- [3] Russell, S. & Norvig, P., 2021, *Artificial Intelligence: A Modern Approach 4rd edition*, Saddle River, NJ: Prentice Hall.
- [4] Oppy, G. & Dowe, D., 2003, "The Turing Test," *The Stanford Encyclopedia of Philosophy* (Winter 2020 Edition), Edward N. Zalta (ed.). Accessed June 1, 2021. <https://plato.stanford.edu/archives/win2020/entries/turing-test/>.
- [5] Cole, D., 2008, "The Chinese Room Argument," *The Stanford Encyclopedia of Philosophy* (Winter 2020 Edition), Edward N. Zalta (ed.). Accessed June 1, 2021. <https://plato.stanford.edu/archives/win2020/entries/chinese-room/>.
- [6] Hodges, A., 2015, "Alan Turing," *The Stanford Encyclopedia of Philosophy* (Winter 2019 Edition), Edward N. Zalta (ed.). Accessed June 1, 2021. <https://plato.stanford.edu/archives/win2019/entries/turing/>.
- [7] Bringsjord, S. & Naveen S., 2012, "Artificial Intelligence," *The Stanford Encyclopedia of Philosophy*. (Summer 2019 Edition), Edward N. Zalta (ed.). Accessed June 1, 2021. <https://plato.stanford.edu/archives/sum2020/entries/artificial-intelligence/>.
- [8] Hofstadter D., 1981, "The Turing Test: A Coffeehouse Conversation," *The Mind's I: Fantasies and Reflections on Self and Soul*, New York, NY: Basic Books, pp. 69-92.
- [9] Dennett D., 1991, "Chapter 14: Consciousness Imagined," *Consciousness Explained*, New York, NY: Back Bay Books, pp. 431-455.
- [10] Putnam H., 1981, "Chapter 1: Brains in a Vat," *Reason, Truth and History*, Cambridge, UK: Cambridge University Press, pp. 1-21.
- [11] 约翰·汉尼斯:《计算机体系结构:量化研究方法(第5版)》,机械工业出版社,2012年。
- [12] 孙会:《意向性与人工智能:基于对“中文屋论证”的批判性考察》,《科技管理研究》,2019年39卷10期,第200-205页。

致谢

感谢李麒麟老师耐心和专业指导！与您的数次讨论常让我醍醐灌顶、受益匪浅。我从大三起开始修哲双，在第一个专业课上就有幸受到过您的指导。您开放的授课风格、极强的学术能力和对学术规范的高要求，让我得以窥见现代哲学学术研究的魅力与门槛。而您的严谨与热忱则深深打动了我，让我为之倾佩。深深地感谢您!!!

这两年里听了哲学系的一些课，受到哲学系众多老师的启发，我感到十分幸运。哲学首先是一种反思的态度，这于我而言是生活的根本。而两年的哲学教育，虽为时不长，但却让我得以拾慧。作为一个对本专业不那么感兴趣但还是继续学了下去的学生，我在哲学领域里找到了真正的兴趣、热情、思考和共鸣。想问题总是让人那么激动！诚然此哉，我也明白真正要在这条道路上走下去，必然要耐得住孤绝、寂寞，要啃读文本，要厘清未明的概念，要与一切模糊和不彻底作斗争。

很遗憾，至少到目前为止，我还是没有敢选择从计算机的主专业道路上走出来。即使心中暗暗期待将来能有机会再修个哲学硕士双学位，也规划着读一个哲学博士，但一切也都还是未知数。感谢北大这个园子，给了我恣意生长的空间，在学业与学业之间，还让我有机会加入外国戏剧研究所、女子篮球校队和院队、校冰壶队和五四文学社。感谢这些社团的小伙伴们，没有你们我精彩的大学生活将黯然失色。

感谢我的舍友，这四年里我们一起成长。感谢我的高中同学刘畅、陈立玮和李天益，你们在我下坠的时候接住我，给了我温暖的支持和帮助。感谢这四年间所有遇见的人，谢谢你们让我看到这个世界的精彩和美好！

感谢我的家人们，尤其感谢我的父母，你们承受了我青春期的叛逆和决绝，也共享了我的荣誉与忧愁。没有你们就不会有现在的我，谢谢你们给了我全部的爱！

感谢我自己，在许许多多困难的时刻咬牙坚持了下来。人生本就是一场漫长而苦难的修行，希望能再接再厉，不要辜负遇见的每一个人。

北京大学学位论文原创性声明和使用授权说明

原创性声明

本人郑重声明：所提交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

论文作者签名：张石然

日期：2021年6月7日

学位论文使用授权说明

本人完全了解北京大学关于收集、保存、使用学位论文的规定，即：

- 按照学校要求提交学位论文的印刷本和电子版；
- 学校有权保存学位论文的印刷本和电子版，并提供目录检索与阅览服务，在校园网上提供服务；
- 学校可以采用影印、缩印、数字化或其它复制手段保存论文；

论文作者签名：张石然

导师签名：



日期：2021年6月7日